

Software Engineering Project

Compression de données pour accélérer la transmission

Daniel Carriba Nosrati

UE Software Engineering Semestre 1 Master 1 Informatique Université Côte d'Azur

2025

Sommaire

1	Intr	roduction	2
2	Bit	Packing	3
		2.0.1 Implémentation commune à toutes les versions	3
	2.1	Bit Packing with overlap	4
		2.1.1 Implémentation	4
		2.1.2 Fonctionnement	4
	2.2	Bit Packing without overlap	5
		2.2.1 Implémentation	5
		2.2.2 Fonctionnement	6
	2.3	Bit Packing with overflow areas	6
		2.3.1 Implémentation	7
		2.3.2 Fonctionnement	7
3	Test	ts Unitaires	9
•	3.1	Implémentation	9
	3.2	Visualisation des résultats des tests	9
4	D	ichmarks	11
4	4.1	Protocole pour mesurer le temps	11 11
	4.1		11
		4.1.1 Phase "warm-up"	11
		4.1.2 Mesures des temps	11
	4.2	Protocole pour mesurer le taux de compression	11
	4.2	4.2.1 Mesures des taux de compression	11
		4.2.2 Calcul du taux moyen sur des entrées variables	12
	4.3	Exemple de résultats des benchmarks	12
	$\frac{4.5}{4.4}$	Interprétation des benchmarks obtenus	13
	4.4	4.4.1 Benchmarks de taux de compression	13
		4.4.1 Benchmarks de taux de compression	13
		4.4.2 Denchmarks de temps	13 14
		4.4.5 Conclusion sur les benchmarks	14
5		nps de transmission pour une latence t où la compression	
			15
	5.1	Protocole pour le calcul	15
	5.2	Calcul sur des entrées variables	15
	5.3	Exemple de résultats	15
	5.4	Interprétation des résultats obtenus	16
	5.5	Conclusion sur les temps de transmissions	17
6	Tab	leaux avec des nombres négatifs	18
	6.1	Problème	18
	6.2	Solution possible	18
7	Con	nclusion	19

1 Introduction

Ce projet, réalisé pour l'UE "Software Engineering" du Semestre 1 du Master 1 Informatique de l'Université Côte d'Azur, est un projet sur le thème de compression de données pour accélérer la transmission.

La transmission de tableaux d'entiers est un problème majeur de l'internet. Ce projet propose une réponse à ce problème en implémentant une méthode de compression de tableaux d'entiers positifs, basés sur le nombre de bits utilisés. Cette méthode de compression est appelée "Bit Packing". Plusieurs versions de cette méthode ont été implémentés par ce projet. L'utilisateur peut ainsi compresser un tableau d'entiers positifs, ainsi que le décompresser. L'accès direct aux éléments n'est pas perdu lors de la compression, l'utilisateur peut toujours avoir un accès immédiat à un i-ème élément du tableau.

Ce projet à été réalisé en Java. Les différentes versions la méthode de compression "Bit Packing" ainsi que leurs implémentations et fonctionnements seront présentés dans ce rapport.

Ce projet donne pour résultats des benchmarks, sous forme de mesures de temps et de taux de compression, pour chaque versions de la méthode de compression. L'implémentation ainsi que la pertinence de ces benchmarks sont expliqués dans la suite de ce rapport, dans la section dédiée.

Pour finir, ce projet calcule également le temps de transmission pour une latence t où chaque version de la méthode de compression devient utile. Le fonctionnement de ceci et les conclusions à en tirées sont également expliqués dans la section dédiée, à la fin de ce rapport.

2 Bit Packing

La méthode de compression "Bit Packing" à été implémenté en trois versions différentes dans ce projet. Chaque version sera présenté en détails dans sa section dédiée.

Pour l'implémentation j'ai choisi donc de créer une classe par versions. Ces classes héritent de la classe abstraite *BitPacking*, qui elle contient les champs et méthodes communes à toutes les versions différentes de "Bit Packing". Chaque classe qui hérite donc de *BitPacking* implémente sa propre méthode pour compresser ainsi que pour accéder au i-ème élément du tableau compressé. Une méthode standard de décompression qui utilise la méthode pour accéder au i-ème élément du tableau compressé pour tout les i est également implémenté par *BitPacking*, mais peut être aussi implémenter dans les versions différentes, pour une décompression plus efficace par exemple.

Voici un schéma UML montrant une vue d'ensemble de la structure de ces classes :

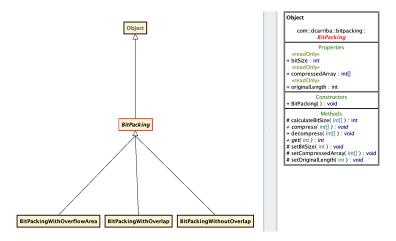


Figure 1: Schéma UML BitPacking

2.0.1 Implémentation commune à toutes les versions

Toutes les versions de "Bit Packing" héritent donc d'une classe abstraite *BitPacking*. Celle-ci contient les champs (i.e. les attributs) ainsi que les méthodes communes à toutes les versions différentes, soit :

- le contenu du tableau compressé
- la taille du tableau original
- le nombre de bits sur lequel chaque valeurs sera codé dans le tableau compressé

- une méthode pour calculer ce nombre de bits
- une méthode de décompression commune, qui récupère chaque élément d'index i grâce à la méthode :

```
public abstract int get(int i);
(implémenté dans chaque version)
```

Une classe *BitPackingTest* a également été implémenté contenant des tests unitaires pour tester le bon fonctionnement de la méthode calculant le nombre de bits sur lequel chaque valeurs sera codé dans le tableau.

2.1 Bit Packing with overlap

La première version de "Bit Packing" de ce projet est une version nommé "with overlap". Cela signifie que une valeur, du tableau à compresser, peut être compressé sur deux entiers consécutifs au sein du tableau compressé.

2.1.1 Implémentation

Cette version de "Bit Packing" a été implémenté par la classe BitPackingWithOverlap qui hérite de la classe abstraite BitPacking.

BitPackingWithOverlap implémente les méthodes abstraites de BitPacking, soit :

Une classe BitPackingWithOverlapTest a également été implémenté contenant des tests unitaires pour tester le bon fonctionnement de la compression, décompression et accès au i-ème élément.

2.1.2 Fonctionnement

Compression: la compression fonctionne de la manière suivante :

- on calcule le nombre de bits nécessaire pour coder la plus grande valeur du tableau initial, afin de codé toutes les valeurs sur ce nombre de bits
- on donc calculer le nombre d'entiers de 32 bits nécessaire pour contenir toutes les valeurs compressé, ce qui est donc la taille du tableau compressé

• pour chaque valeur du tableau inital, on le code sur le premier entier où il peut être compressé, et si il ne peut pas être contenu entièrement sur cet entier, on continue de le compresser sur l'entier suivant.

Ainsi chaque valeur du tableau initial est codé sur N bits (i.e. le nombre de bits nécessaire pour coder la plus grande valeur du tableau initial) sur un entier du tableau compressé, ou sur deux entiers consécutifs du tableau compressé si il ne peut être contenu entièrement sur le premier entier.

Accès au i-ème élément : l'accès au i-ème élément fonctionne de la manière suivante :

- on connait le nombre de bits sur lequel toutes les valeurs ont été codées, donc il suffit de calculer sur quel entier de 32 bits la i-ème valeur à été compressé.
- on calcul la position de la i-ème valeur au sein de cet entier (de 32 bits), et on extrait la valeur, puis la renvoie. Si la i-ème valeur n'est pas entièrement compressé sur cet entier, on continu de l'extraire l'entier suivant .

Décompression : la décompression fonctionne de la manière suivante :

- pour tout valeur i il suffit d'utiliser la méthode pour accéder au i-ème élément pour la récupérer
- toutes les valeurs récupérés peuvent ainsi être rétablis dans le tableau décompressé

2.2 Bit Packing without overlap

La seconde version de "Bit Packing" de ce projet est une version nommé "without overlap". Cela signifie que une valeur, du tableau à compresser, sera toujours compressé sur un seul, et non deux, entier du tableau compressé.

2.2.1 Implémentation

Cette version de "Bit Packing" a été implémenté par la classe BitPackingWithoutOverlap qui hérite de la classe abstraite BitPacking.

BitPackingWithoutOverlap implémente les méthodes abstraites de BitPacking, soit :

Une classe BitPackingWithoutOverlapTest a également été implémenté contenant des tests unitaires pour tester le bon fonctionnement de la compression, décompression et accès au i-ème élément.

2.2.2 Fonctionnement

Compression : la compression fonctionne de la manière suivante :

- on calcule le nombre de bits nécessaire pour coder la plus grande valeur du tableau initial, afin de codé toutes les valeurs sur ce nombre de bits
- on calcule ensuite le nombre de valeurs qui peuvent être codés sur un seul entier de 32 bits, et par conséquent la taille du tableau compressé
- pour chaque valeur du tableau inital, on le code sur le premier entier où il peut être contenu entièrement

Ainsi chaque valeur du tableau initial est codé sur N bits (i.e. le nombre de bits nécessaire pour coder la plus grande valeur du tableau initial) d'un entier (32 bits) du tableau compressé.

Accès au i-ème élément : l'accès au i-ème élément fonctionne de la manière suivante :

- on connait le nombre de bits sur lequel toutes les valeurs ont été codées, donc il suffit de calculer sur quel entier de 32 bits la i-ème valeur est situé.
- on calcul la position de la i-ème valeur au sein de cet entier (de 32 bits), et on extrait la valeur, puis la renvoie.

Décompression : la décompression fonctionne de la manière suivante :

- pour tout valeur i il suffit d'utiliser la méthode pour accéder au i-ème élément pour la récupérer
- toutes les valeurs récupérés peuvent ainsi être rétablis dans le tableau décompressé

2.3 Bit Packing with overflow areas

La troisième version de "Bit Packing" de ce projet est une version nommé "with overflow areas". Elle fonctionne de la manière suivante :

Si un nombre du tableau initial nécessite un grand nombre de bits k et que les autres nombres nécessitent seulement k' bits avec k' < k, il est inutile de représenter tous les nombres avec k bits. Dans ce cas, nous pouvons attribuer une valeur spéciale à un entier compressé pour indiquer que sa valeur réelle se trouve ailleurs, à une position spécifique du tableau, appelée zone de débordement, ou "overflow area".

Par exemple, si nous voulons encoder les nombres 1, 2, 3, 1024, 4, 5 et 2048, nous pouvons encoder 1, 2, 3 et 4 sur 3 bits et les autres nombres sur 11 bits.

Nous utiliserons un bit du codage pour indiquer que nous ne représentons pas directement un nombre, mais une position dans la zone de débordement. Si 1 correspond à la zone de débordement, et si x-y signifie que le premier bit vaut x et les suivants y, nous représenterons la séquence de nombres 1, 2, 3, 1024, 4, 5, 2048 par : 0-1, 0-2, 0-3, 1-0, 0-4, 0-5, 1-1, 1024, 2048.

2.3.1 Implémentation

Cette version de "Bit Packing" a été implémenté par la classe BitPackingWithOverflowArea qui hérite de la classe abstraite BitPacking.

BitPackingWithOverflowArea implémente les méthodes abstraites de BitPacking, soit :

Ainsi que une méthode de décompression plus efficace pour BitPackingWithOverflowArea que celle déjà existante de BitPacking:

Une classe BitPackingWithOverflowAreaTest a également été implémenté contenant des tests unitaires pour tester le bon fonctionnement de la compression, décompression et accès au i-ème élément.

2.3.2 Fonctionnement

Compression: la compression fonctionne de la manière suivante :

- on calcule N le nombre de bits nécessaire pour coder la plus grande valeur du tableau initial. Toute valeur qui doit réellement être codé sur N bits sera une valeur compressé dans la "overflow area", et les autres valeurs, qui peuvent être codés sur N' < N bits, seront compressé sur N' bits de manière normale.
- pour toutes les valeurs du tableau initial, on compresse dont soit la valeur sur N' bit (en ajoutant un bit 0 supplémentaire avant), soit on compresse l'index de la valeur dans l' "overflow area" (en ajoutant un bit 1 supplémentaire

avant). A la fin, toutes les valeurs de l' "overflow area", i.e. les valeurs compressé sur N bits, seront ajoutés à la fin du tableau compressé.

Ainsi les grandes valeurs (i.e. celles qui doivent être compressé sur N bits) seront compressé dans l' "overflow area", à la fin du tableau compressé, et avant dans le tableau compressé sera seulement une référence (de forme 1-overflowValueIndex) à sa position au sein de l' "overflow area".

Décompression : la décompression fonctionne de la manière suivante :

- on parcours le tableau compressé de bit en bit.
- Si le bit indicateur est 0 alors cela signifie que la valeur a été compressé de manière normale sur N' bits. On peut donc facilement la décompresser et ajouter au tableau de résultat.
- Si le bit indicateur est 1 alors cela signifie que la valeur a été compressé dans l' "overflow area". On sauvegarde donc l'indice actuel où la valeur devrait être, pour compléter l'indice à la fin lors de la décompression de la valeur de l' "overflow area"

Accès au i-ème élément : l'accès au i-ème élément fonctionne de la manière suivante :

- pour pouvoir déterminer si la i-ème valeur a été compressé de manière normale sur N' bits, ou dans l' "overflow area" sur N bits, il est nécessaire de parcourir le tableau compressé de bit en bit pour lire les bits indicateurs (0, ou 1 si la valeur est compressé dans l' "overflow area"). Ce procédé revient exactement à faire une décompression, comme l'entièreté du tableau compressé, pour notamment extraire les valeurs des éléments compressé dans l' "overflow area".
- ainsi on décompresse temporairement le tableau pour pouvoir donné la valeur du i-ème élément.

3 Tests Unitaires

3.1 Implémentation

Pour vérifier le bon fonctionnement des méthodes pour compresser, décompresser at accéder au i-ème élément du tableau compressé, on a implémenter des tests unitaires pour les classes de "Bit Packing". Ces tests unitaires sont situés dans le répertoire :

```
./src/test/java/
```

Les tests unitaires implémentés sont :

- BitPackingTest contient les tests unitaires pour BitPacking
- BitPackingWithOverlapTest contient les tests unitaires pour BitPackingWithOverlap
- BitPackingWithoutOverlapTest contient les tests unitaires pour BitPackingWithoutOverlap
- BitPackingWithOverflowAreaTest contient les tests unitaires pour BitPackingWithOverflowArea

BitPackingWithOverlapTest, BitPackingWithoutOverlapTest et BitPackingWithOverflowAreaTest étendent la classe BitPackingVersionsBaseTest qui contient la logique des tests unitaire, commune pour ces 3 versions de "Bit Packing".

3.2 Visualisation des résultats des tests

Les tests unitaires sont exécutés avec la commande suivante :

```
./gradlew test
```

Si "BUILD SUCCESSFUL" s'affiche, alors tout les tests unitaires on été exécutés avec succès.

Une visualisation sur l'ensemble des résultats est également disponible sur :

./ build/reports/tests/test/index.html

Figure 2: Tests unitaires exécutés avec succès

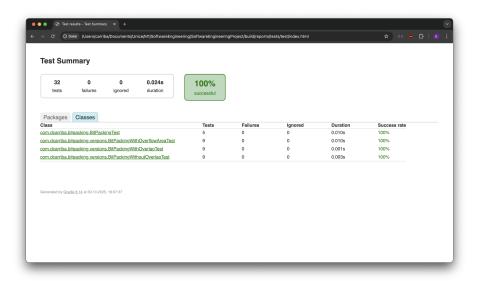


Figure 3: Visualisation des résultats des tests unitaires

4 Benchmarks

4.1 Protocole pour mesurer le temps

Pour mesurer la performance en temps des méthodes des différentes versions de "Bit Packing", on a choisit un protocole constitué des étapes suivantes.

4.1.1 Phase "warm-up"

Avant de mesurer les temps, il est important de faire une phase de "warm-up" (échauffement), afin d'assurer que les optimisations de la JVM, comme la compilation "Just-in-time", n'affecte pas les résultats finaux du benchmark.

4.1.2 Mesures des temps

La mesure de temps s'effectue grâce à la "Java Virtual Machine's high-resolution time source" en nano-secondes :

```
System.nanoTime();
```

qui est appelé avant et après l'execution de la méthode à mesurer. La différence entre ces 2 temps nous donne donc le temps écoulé pendant l'exécution de la méthode à mesurer.

La classe *TimeBenchmarks* implémente les méthodes pour mesurer ainsi le temps pour les méthodes de compression, décompression et accès au i-ème élément du tableau compressé.

4.1.3 Calcul du temps moyen sur des entrées variables

Nous choisissons de prendre la moyenne sur un nombre N (ici 10, mais modifiable grâce à une constante dédiée dans la classe *Config*) de répétitions de mesures de temps. De plus, à chaque répétition le tableau obtient de nouvelles valeurs aléatoires. Ceci nous assure donc un calcul de temps moyens plus fiable.

Ces benchmarks sont exécutés à plusieurs reprises avec plusieurs tableaux de taille différents, pour ainsi obtenir des temps moyens pour des tailles de tableaux différents, et donc pouvoir comparer les temps par rapport à la version de *BitPacking* et par rapport à la taille du tableau en entrée.

La classe RunTimeBenchmarks s'occupe d'exécuter ces benchmarks, et est appelée dans la fonction main de la classe Main.

4.2 Protocole pour mesurer le taux de compression

4.2.1 Mesures des taux de compression

La mesure du taux de compression s'effectue en compressant un tableau, et en calculant le résultat de la division suivante :

bitPacking.getCompressedArray().length / array.length

où "bitPacking" est un objet de type BitPacking qui contient le tableau compressé de "array".

Par exemple, si le taux de compression est de 0.5 alors cela signifie que le tableau compressé fait 50% de la taille du tableau initial.

Ainsi, un taux de compression bas est considéré étant meilleur.

La classe CompressionRatioBenchmarks implémente la méthodes qui effectue ce calcul de taux de compression

4.2.2 Calcul du taux moyen sur des entrées variables

Nous choisissons de prendre la moyenne sur un nombre N (ici 10, mais modifiable grâce à une constante dédiée dans la classe Config) de répétitions de mesures de taux de compression. De plus, à chaque répétition le tableau obtient de nouvelles valeurs aléatoires. Ceci nous assure donc un calcul du taux de compression plus fiable.

Ces benchmarks sont exécutés à plusieurs reprises avec plusieurs tableaux contenant chacun des valeurs maximales différentes. Ainsi on peut donc comparer le taux de compression des différentes versions en fonction des valeurs contenus à l'intérieur des tableaux en entrée.

4.3 Exemple de résultats des benchmarks

```
$ ./gradlew run
> Task :run
| *** BIT PACKING BENCHMARKS *** |
*** Compression Ratio Benchmarks ***
Results of the compression ratio benchmarks, using randomly generated arrays
with different possible maximum values:
=== Average Compression Ratio (average over 10 repetitions) ===
Max Possible Value
                                             Without Overlap
                                                                With Overflow Area
                         With Overlap
                         0,03
                                             0,03
                                                                 0,38
10
                         0,13
                                             0,13
                                                                 0,18
100
                         0,22
                                             0,25
                                                                 0,33
256
                         0,25
                                             0,25
                                                                 0,41
1000
                         0,31
                                             0,33
                                                                 0,46
5000
                         0,41
                                             0,50
                                                                 0,46
10000
                         0,44
                                             0,50
                                                                 0,49
2097151
                         0.66
                                             1.00
                                                                 0.82
16777215
                         0,75
                                             1,00
                                                                 0,91
1073741823
                                             1,00
                                                                 1,09
2147483647
*** Time Benchmarks ***
Warming up the JVM for better results...
Warm-up completed.
Results of the time measurements benchmarks, using randomly generated arrays
```

at different sizes:

```
=== Average Compression Time (in micro-seconds) (average over 10 repetitions) ===
                                  Without Overlap
Array Size
              With Overlap
                                                      With Overflow Area
100
              0.82
                                  0.31
                                                      7.15
500
              3,59
                                  0,86
                                                      95,45
1000
              7,02
                                  1,68
                                                      331,11
5000
                                  7.84
                                                      7566,23
              33.59
=== Average Decompression Time (in micro-seconds) (average over 10 repetitions) ===
Array Size
              With Overlap
                                  Without Overlap
                                                      With Overflow Area
100
              3,85
                                  2,39
                                                      1.89
500
              8,08
                                  7,19
                                                      8,57
1000
                                                      16,58
              5.96
                                  8,40
5000
              21,68
                                  7,68
                                                      86.25
=== Average Get Time (in nano-seconds) (average over 10 repetitions) ===
                                                      With Overflow Area
Array Size
             With Overlap
                                  Without Overlap
100
              5,50
                                  2,20
                                                      1167,80
500
              5,00
                                  2,00
                                                      6083.40
1000
              5,10
                                  2,40
                                                      12364,90
5000
              5,00
                                  2.00
                                                      70411.00
BUILD SUCCESSFUL in 8s
2 actionable tasks: 1 executed, 1 up-to-date
```

4.4 Interprétation des benchmarks obtenus

4.4.1 Benchmarks de taux de compression

On peut remarquer que la version "With Overlap" a un taux de compression toujours meilleurs que les autres versions de la méthode de compression.

De plus on remarque que les taux de compression de chaque version est différent de la valeur maximale contenu dans le tableau à compressé. Ainsi plus cette valeur maximale est inférieur, mieux le taux de compression est.

Le taux de compression de la version "Without Overlap" est le second meilleur si la valeur maximale du tableau à compressé est particulièrement petite ou grande. Sinon pour une valeur maximale relativement moyenne, la version "With Overflow Area" donne de meilleurs taux que la version "Without Overlap". Pour des petites valeurs maximales, la version "With Overflow Area" n'est pas très optimisé, et pour des valeurs maximales très élevées, la version "With Overflow Area" a même un tableau compressé de taille plus grande que le tableau original.

Ainsi on peut donc conclure que la version "With Overlap" donne toujours le meilleurs taux de compression, et que la version "With Overflow Area" n'est pas adapté si la valeur maximale du tableau à compressé est particulièrement petite ou particulièrement grande.

4.4.2 Benchmarks de temps

On peut remarquer que la version "Without Overlap" à presque toujours les meilleurs temps pour la compression, la décompression et pour l'accès au i-ème élément du tableau compressé.

La version "With Overlap" a également des temps correctes vis-à-vis de la compression, décompression et accès au i-ème élément.

Cependant, la version "With Overflow Area" a dans la majorité des cas les temps les plus élevées. Notamment pour l'accès au i-ème élément on remarque un temps particulièrement élevée. Ceci-ci est surement dû à mon implémentation de cette méthode, qui est obligée de systématiquement décompresser le tableau avant de pouvoir déterminer le i-ème élément.

Ainsi on peut donc conclure que les meilleurs versions de "Bit Packing" en fonction du temps sont les versions "Without Overlap" suivi par "With Overlap" et finalement "With Overflow Area", qui a des temps considérablement supérieur au autres versions.

4.4.3 Conclusion sur les benchmarks

Grâce au différents benchmarks obtenus, on peut conclure que la meilleur version de "Bit Packing" en considérant le temps de compression, décompression et accès au i-ème est la version "Without Overlap".

Si on considère le taux de compression, on peut conclure que la version "With Overlap" de "Bit Packing" offre les meilleurs résultats.

5 Temps de transmission pour une latence t où la compression devient utile

Pour déterminer si, et quand, la compression de tableaux d'entiers positifs est utile pour répondre au problème initiale, soit la transmission de ces tableau à travers internet, ce projet calcule le temps de transmission pour une latence t où la compression devient utile, pour chaque version de la compression "Bit Packing" qui a été implémenté.

5.1 Protocole pour le calcul

Le calcul est effectué par la classe CalculateTransmissionTimeAndIfWorth, qui calcule :

- le temps de transmission du tableau sans compression
- pour chaque version de compression : le temps de transmission du tableau compressé (à l'aide du temps de compression et de décompression, calculé par les benchmarks de temps)
- si la compression est utile, i.e. si le temps de transmission du tableau compressé (qui inclus le temps de compression et de decompression) est inférieur au temps de transmission du tableau non compressé

Pour les calculs de transmission, on a choisi d'assumer pour le taux de transmission la moyenne, qui est de 10 Mbps.

5.2 Calcul sur des entrées variables

La classe RunCalculateTransmissionTimeAndIfWorth utilise donc la classe présentés précédemment pour effectuer les calculs sur des tableaux en entrées avec des tailles différentes, et avec des éléments de valeurs maximales possibles différentes également, pour des résultats sur des entrées un maximum variées.

5.3 Exemple de résultats

```
$ ./gradlew run
> Task : run
| *** BIT PACKING BENCHMARKS *** |
_____
       Transmission Time calculation
*** and if the compression is worth or not ***
=== Using an array with size 1000 ===
                                 With Overlap
Max Possible Value
                    T_{without}
                                                                            With Overflow Area
                                 T_{time}
                                            is worth?
                                                       T_{time}
                                                                is worth?
                                                                            T_{time}
                                                                                       is worth?
                    0,003200
                                 0,000376
                                                       0,000252
                                                                             0,001955
                    0,003200
                                 0,000502
                                                       0,000465
                                                                            0,002286
10
                                            true
                                                                  true
                    0,003200
                                 0,000816
                                                       0,000855
                                                                 true
                                                                             0,001437
                                            true
                                                                                       true
```

```
256
                        0,003200
                                       0,000892
                                                                0,000853
                                                                                          0,001746
                                                    true
                                                                             true
                                                                                                       true
1000
                        0.003200
                                       0.001105
                                                    true
                                                                0.001121
                                                                             true
                                                                                          0.001899
                                                                                                      true
5000
                                       0,001358
                                                                0,001656
                                                                                          0,001855
                        0.003200
                                                    true
                                                                             true
                                                                                                      true
10000
                        0,003200
                                       0,001433
                                                                0,001656
                                                    true
                                                                             true
                                                                                          0,001937
                                                                                                      true
2097151
                        0.003200
                                       0,002136
                                                                0,003257
                                                                                          0,003048
                                                                             false
                                                    true
                                                                                                      true
16777215
                        0.003200
                                       0.002431
                                                                0.003255
                                                                                          0.003387
                                                    true
                                                                             false
                                                                                                      false
1073741823
                                                                0,003257
                        0.003200
                                       0.003051
                                                                                          0.003949
                                                    true
                                                                             false
                                                                                                      false
2147483647
                        0.003200
                                       0.003136
                                                                0.003256
                                                                                          0.004070
                                                    true
                                                                             false
                                                                                                      false
=== Using an array with size 15000 ===
                                       With Overlap
Max Possible Value
                        T without
                                                                Without Overlap
                                                                                          With Overflow Area
                                       T_{time}
                                                    is worth?
                                                                T_{time}
                                                                             is worth?
                                                                                         T_{time}
                                                                                                      is worth?
                                       0.001890
                                                                0.001892
                        0.048000
                                                    true
                                                                             true
                                                                                          0.025311
                                                                                                      true
10
                        0.048000
                                       0.006191
                                                    true
                                                                0,006166
                                                                             true
                                                                                          0,028015
                                                                                                      true
100
                        0,048000
                                       0,010658
                                                    true
                                                                0,012223
                                                                             true
                                                                                          0,044309
                                                                                                      true
256
                        0.048000
                                       0.012107
                                                    true
                                                                0.012074
                                                                             true
                                                                                          0.051079
                                                                                                      false
1000
                        0,048000
                                       0,015129
                                                    true
                                                                0,016064
                                                                             true
                                                                                          0,065315
                                                                                                      false
5000
                        0,048000
                                       0,019623
                                                    true
                                                                0,024045
                                                                             true
                                                                                          0,061644
                                                                                                       false
10000
                        0,048000
                                       0,021127
                                                                0,024045
                                                                             true
                                                                                          0,072288
                                                                                                       false
                                                    true
2097151
                        0,048000
                                       0,031640
                                                    true
                                                                0,048048
                                                                             false
                                                                                          0,117700
                                                                                                      false
                                                    true
16777215
                        0,048000
                                       0,036134
                                                                0,048046
                                                                             false
                                                                                          0,122586
                                                                                                      false
1073741823
                        0.048000
                                       0.045163
                                                    true
                                                                0.048051
                                                                             false
                                                                                          0.131956
                                                                                                      false
                                                                0,048055
                                                                                          0,134984
2147483647
                        0,048000
                                       0,046672
                                                                                                      false
                                                    true
                                                                             false
Notice:
- "T_without" is the Transmission Time (in seconds) of the array without compression - for each compression version "T_time" is the Transmission Time (in seconds) of the array,
compressed using that compression version
 for each compression version "is worth?"
                                                 indicates if the compression was worth,
i.e. if it improved the Transmission Time
 in the calculations the average transmission rate of 10 Mbps is used
BUILD SUCCESSFUL in 3s
2 actionable tasks: 2 executed
```

5.4 Interprétation des résultats obtenus

Les résultats obtenus ci-dessus montrent pour les tableaux des taille 1000 et 15000, pour chaque valeur maximale possible, le temps de transmission du tableau non compressé (représenté par la colonne "T without"), ainsi que pour chaque version de compression "Bit Packing" le temps de transmission du tableau compressé (représenté par la colonne "T time"). Si "T time" est inférieur à "T without", alors la compression s'est avéré utile et bénéfique pour améliorer le temps de transmission. Ceci est représenté par la colonne "is worth?".

Ainsi on remarque donc que la version de compression "With Overlap" améliore toujours le temps de transmission du tableau.

La version de compression "Without Overlap" améliore le temps de transmission du tableau seulement si la valeur maximal possible dans le tableau ne dépasse un certain seuil (entre 10000 et 2097151 d'après nos résultats).

La version de compression "With Overflow Area" améliore le temps de transmission seulement si la valeur maximal possible du tableau est en dessous d'un seuil. Ce seuil dépend, comme on peut le remarquer, de la taille du tableau en entier. Si la taille du tableau est de 1000 alors la version de compression "With Overflow Area" est utile seulement si la valeur maximale possible est inférieur 2097151, alors que si la taille du tableau est de 15000, "With Overflow Area" est seulement utile si la valeur maximale possible est de 100.

Les versions "With Overlap" et "Without Overlap" ne dépendent pas de la taille du tableau, mais seulement de la valeur maximale possible au sein du tableau, au contraire de la version de compression "With Overflow Area".

5.5 Conclusion sur les temps de transmissions

Grâce à nos résultats obtenus, on peut donc conclure que la version "With Overlap", de la méthode de compression de "Bit Packing", améliore toujours le temps de transmission d'un tableau d'entiers positifs par internet, comparé au temps de transmission de ce tableau sans le compressé. Au contraire, les versions "Without Overlap" et "With Overflow Area" n'améliorent pas toujours ce temps de compression. Ainsi compresser le tableau avec la version "With Overlap" de "Bit Packing" s'avère utile et bénéfique pour améliorer le temps de transmission de tableau d'entiers positifs par internet.

6 Tableaux avec des nombres négatifs

Considérons que les tableaux à transmettre peuvent contenir des nombres négatifs. Nous expliquerons le problème que ceci pourrait causer avec la méthode de compression "Bit Packing" implémenté par ce projet. Nous proposerons également une solution possible, pour résoudre ce problème.

6.1 Problème

Comparé à des nombres positifs, le codage binaire de nombres négatifs est différent. En effet, il s'effectue grâce au complément à deux. Ainsi les nombres négatifs on pour caractéristique que le bit de poids fort est un "1", et que l'ensemble du codage binaire est en complément à deux.

La méthode de compression "Bit Packing" compresse les nombres en supprimants tout les bits "0" inutiles au codage binaire du nombre à compressé. Comme les nombres négatifs sont codés en complément à deux, les "0" inutiles deviennent des "1", et ainsi il est impossible de compresser ces nombres négatifs avec l'implémentation actuelle de "Bit Packing".

6.2 Solution possible

Une solution possible pour remédier au problème décrit ci-dessus, serait d'utiliser le méthode d'encodage appelé "Zigzag encoding".

La méthode d'encodage "Zigzag encoding" est un encodage qui convertit en nombre positif les nombres négatifs. Il fait ceci en attribuant une nouvelle valeur positif pour chaque nombre, en alternant nombre positif et négatif.

Ainsi on aura par exemple : 0 devient 0, -1 devient 1, 1 devient 2, -2 devient 3, 2 devient 4, -3 devient 5, 3 devient 6, etc.

La méthode "Zigzag" peut donc facilement convertir les nombres négatifs en positifs, et peut également simplement reconstruire la valeur initiale, grâce à des formules mathématiques. Intégrer une méthode pour convertir tout les nombres en encodage "Zigzag" avant d'effectuer la compression avec notre méthode de "Bit Packing" serait donc une solution efficace pour résoudre le problème évoqué ci-dessus, et la méthode de compression "Bit Packing" pourrait donc fonctionner sur tout les nombres et non les nombres positifs seulement.

7 Conclusion

La transmission de tableaux d'entiers est un problème majeur de l'internet. Ce projet essaie donc de répondre a ce problème en implémentant une méthode de compression de tableaux d'entiers positifs, appelée "Bit Packing", qui est une méthode de compression basés sur le nombre de bits utilisés.

On a pu voir les 3 différentes versions, appelés "With Overlap", "Without Overlap" et "With Overflow Area", de cette méthode de compression, qui ont été implémentés par ce projet, ainsi que des benchmarks, sur le temps et sur le taux de compression. Ceci nous a donc permis de comparer ces 3 versions.

Grâce au benchmark de temps, qui mesurent le temps écoulé pour la compression, la décompression ainsi que pour l'accès au i-ème élément du tableau compressé, pour chacune des 3 versions, on a pu conclure que la version ayant les meilleurs benchmarks de temps était la version "Without Overlap" suivi de la version "With Overlap".

Grâce au benchmarks de taux de compression, on a pu conclure que la version "With Overlap" donne toujours le meilleurs taux de compression, suivi de la version "Without Overlap".

Finalement, grâce au calcul du temps de transmission pour une latence t où la compression devient utile, on a pu conclure que la version "With Overlap" est la seul version de la méthode "Bit Packing" qui améliore toujours le temps de transmission pour un tableau, comparé au temps de transmission d'un même tableau sans aucune compression.

Pour conclure, les benchmarks et calculs que notre projet fournis vis-à-vis des versions implémentés de la méthode de compression "Bit Packing", nous indiquent donc que la version "With Overlap", c'est à dire la version où une valeur, du tableau à compresser, peut être compressé sur deux entiers consécutifs au sein du tableau compressé, est la meilleur version de la méthode de compression "Bit Packing".